

LINE AI Chat 成本報告

日期：2026-09-25 | 範圍：LINE 官方帳號 AI Chat 五層架構的 AI 分層成本與 TCO 基底：AWS Amplify SSR + DynamoDB (只計 AI 分層與向量搜尋的增量成本) 配套：完整架構見 [line-ai-chat-architecture-and-tco-2026-09-25.md](#) ; 可調試算表 [line-ai-chat-cost-model.xlsx](#)

一、結論 (TL;DR)

1. 現況每月 < 1,000 則訊息 = AI 成本每月不到 US\$0.5 (NT\$14 上下) 。此流量下任何自建 GPU 或 RunPod 方案都是浪費。
2. 每則混合成本 431 μ\$ ≈ NT\$0.0138 。其中 LLM 佔約 96% ，而只佔 5% 流量的 L5 (高階模型/真人) 就吃掉 62% 的成本。
3. 降成本最大的槓桿是壓低 L5 命中率 (把複雜問題盡量在 L1–L4 解決) ，效果遠大於在 L4 換更便宜的模型。
4. 純雲 Pay-as-you-go (方案 A) 在所有可預見流量都是最便宜。自建 GPU 要每月約 250 萬則、RunPod 常駐 worker 要約 186 萬則才追平純雲——是現況的 2,000 倍以上。
5. 建議：留在方案 A，直到月訊息量 > 50 萬則或 AI 月費連三個月 > US\$200 再重新評估。本機/RunPod 保留為可插拔選項，不提前投資。

二、假設與計價基礎

- 匯率 FX = 32 NT\$/US\$; 成本以 micro-USD (μ\$, 1 USD = 1,000,000 μ\$) 計，對齊系統帳本 [ai-usage-ledger](#) 。
- 分層命中率 (可調) : L1 30% / L2 25% / L3 20% / L4 20% / L5 5% 。
- 累積成本概念：一則走到 L5 的訊息，已先付了 L1+L2+L3+L4，因此用 $blended = \sum \text{命中率} \times \text{累積成本}$ 衡量，而非單看某層。
- L4 主模型 Gemini 3.1 Flash-Lite (\$0.25/\$1.50 每 M) ; L5 Claude Haiku 4.5 (\$1.00/\$5.00 每 M) ; embedding text-embedding-3-small (\$0.02/M) 。
- 每則 token 假設：L4 輸入 1,960 / 輸出 180 ; L5 輸入 2,760 / 輸出 350 ; embedding 60 。
- AWS 增量 (DynamoDB on-demand、Lambda 計費模型) 免費額度視為已被平台其他流量用掉 (保守) 。

三、每則訊息成本拆解

層	該層新增 inc (μ\$)	累積 cum (μ\$)	命中率	貢獻 (μ\$)
L1 Postback / 圖文選單	2.8	2.8	30%	0.8
L2 Keyword / Regex 規則	0	2.8	25%	0.7
L3 Semantic FAQ 向量	8.0	10.8	20%	2.2
L4 便宜 LLM (RAG)	787.5	798.3	20%	159.7
L5 高階 / 真人轉接	4,562.5	5,360.8	5%	268.1
混合 (blended)			100%	431.4

每則 431.4 μ\$ ≈ NT\$0.0138。三個要看懂的重點：

- LLM 佔 blended ≈ 96% (L4+L5 的 token 費 415.5 μ\$)。L1–L3 合計不到 12 μ\$，幾乎免費。
- L5 佔 62%：只佔 5% 流量卻是最大成本來源。
- 分層的價值不是省 L1–L3 的錢，而是把 L4/L5 的比例壓下來。

四、方案 A (純雲) 月成本

月訊息量	月費 US\$	≈ NT\$
1,000 (現況上限)	0.43	14
10,000	4.31	138
100,000	43.14	1,380
1,000,000	431.42	13,805

五、三方案比較 (A 純雲 / B RunPod / C 自建 GPU)

B 與 C 只把 L4 LLM 搬離雲端，L1–L3 與 L5 仍在雲端。誠實的總成本 = 雲端 A 總成本 - 雲端 L4 LLM 費 + 替代成本。

月訊息量	A 純雲 US\$	B RunPod US\$	C 自建 GPU US\$	最便宜
1,000	0.43	1.80	441.2	A
10,000	4.31	17.92	443.5	A
100,000	43.14	173.10	466.3	A
1,000,000	431.42	594.01	694.2	A

方案 B (RunPod Serverless)：理論下限 (100% 溫機) 也比雲端便宜 37%，一旦有冷啟 (25 秒) 就被推到 5–8 倍貴。隱藏成本：冷啟期間使用者無回應、模型鏡像儲存、無 SLA。只有在 L4 被迫升到 mini/Haiku 級模型時才有機會贏。

方案 C (自建 RTX 5090) 固定成本 = NT\$14,110/月 ≈ US\$441：

項目	NT\$/月
設備折舊 (NT\$245k / 36 月)	6,806
待機電費 (90W × 730h × 4.5)	296
維護工時 (4h × 1,200)	4,800
UPS / 備援折舊	167
故障 / 升級準備金 (10%/年)	2,042
合計	14,110

維護工時佔 34%，是最大單項。單機無 HA，故障期間 L4 全部要 fallback 到雲端；家用電/網路中斷不在 UPS 涵蓋；折舊期內 GPU 跌價不退錢。

六、損益兩平

比較	損益兩平 (≈ 月訊息量)	備註
C 勝 A (自建 GPU)	≈ 2,475,000 則/月	此時單卡利用率約 59%
B 勝 A (RunPod 常駐 worker)	≈ 1,856,000 則/月	RunPod flex 模式永遠不勝

現況 (< 1,000 則) 距離最近的損益兩平點還有 1,800 倍以上。

七、敏感度 (哪些變數會翻盤)

變數	變動	影響
L5 命中率	5% → 10%	blended 431 → 660 μ\$ (+53%)，最大槓桿
L4 模型等級	Flash-Lite → mini / Haiku	blended 升到 811 / 956 μ\$；C 勝 A 門檻降到 79 萬 / 63 萬則
命中率分布	樂觀 (規則層強) vs 悲觀 (規則層弱)	blended 175 μ\$ vs 1,394 μ\$，差 8 倍
L4 tokens/則	×2 (RAG/歷史加長)	C 勝 A 門檻減半
維護工時	4h → 0h (自欺情境)	C 勝 A 降到 ~163 萬則
電價	4.5 → 9.39 NT\$/度	C 幾乎不動 (< 3%)
L5 prompt cache	命中 50%	blended -14%

啟示：把訊息趕進 L1/L2 (規則層) 的價值，遠大於在 L4/L5 換模型。命中率分布從悲觀到樂觀，成本差 8 倍。

八、決策門檻

- 1. 留在方案 A (純雲) : 直到月訊息量 > 50 萬則 , 或 AI 月費連續 3 個月 > US\$200 。
- 2. 重評方案 B (RunPod 常駐 worker) : 當 L4+L5 請求 > 5,000/日 (≈15 萬/月) 且雲端 L4 單價 ≥ US\$0.002/req , 或需要 API 沒有的模型。RunPod flex 只當「零 CAPEX 試跑本地模型品質」的實驗。
- 3. 考慮方案 C (自建 GPU) : 需三條件同時成立——單卡持續利用率 > 30% (≈130 萬則/月) 、雲端 fallback 已演練、有人承擔每月維護工時。
- 4. 合規例外 : 資料落地/隱私法遵可直接跳 C , 但這是合規成本 , 不是省錢。
- 5. 治理護欄 : 預算 GLOBAL 月上限先設 US\$50 、日上限 US\$5 ; 帳本以 `line-l3/l4/l5` 分開記 , 三個月後用真實用量回填命中率、重算本報告。

九、定價基礎 (2026-09-25 查證)

項目	數值
Gemini 3.1 Flash-Lite (L4 主)	\$0.25 in / \$1.50 out 每 M
GPT-5.4 nano (L4 備)	\$0.20 / \$1.25
Claude Haiku 4.5 (L5)	\$1.00 / \$5.00
text-embedding-3-small	\$0.02 / M
RunPod 24GB flex	\$0.69/hr (每秒計費)
AWS Lambda / DynamoDB	\$0.20/M req + \$0.0000166667/GB-s ; \$0.125/M 讀、\$0.625/M 寫
RTX 5090 (台灣)	NT\$165,990–200,000 ; 575W
台電營業用電	預設 NT\$4.5/度

模型單價已同步寫入系統計費表 `lib/ai/gateway/pricing.ts` (含中國模型 DeepSeek / Qwen / Kimi / GLM , 為概略快照 , 正式計費前於 Phase 0b 以真實帳單校準) 。完整來源連結見架構文件 §11 。

本報告數字由 `line-ai-chat-cost-model.xlsx` (Inputs 驅動全公式) 與 Python 鏡射公式雙重核對一致。改動試算表 Inputs (命中率、token 數、模型單價、電價等) 即自動重算全部結論。